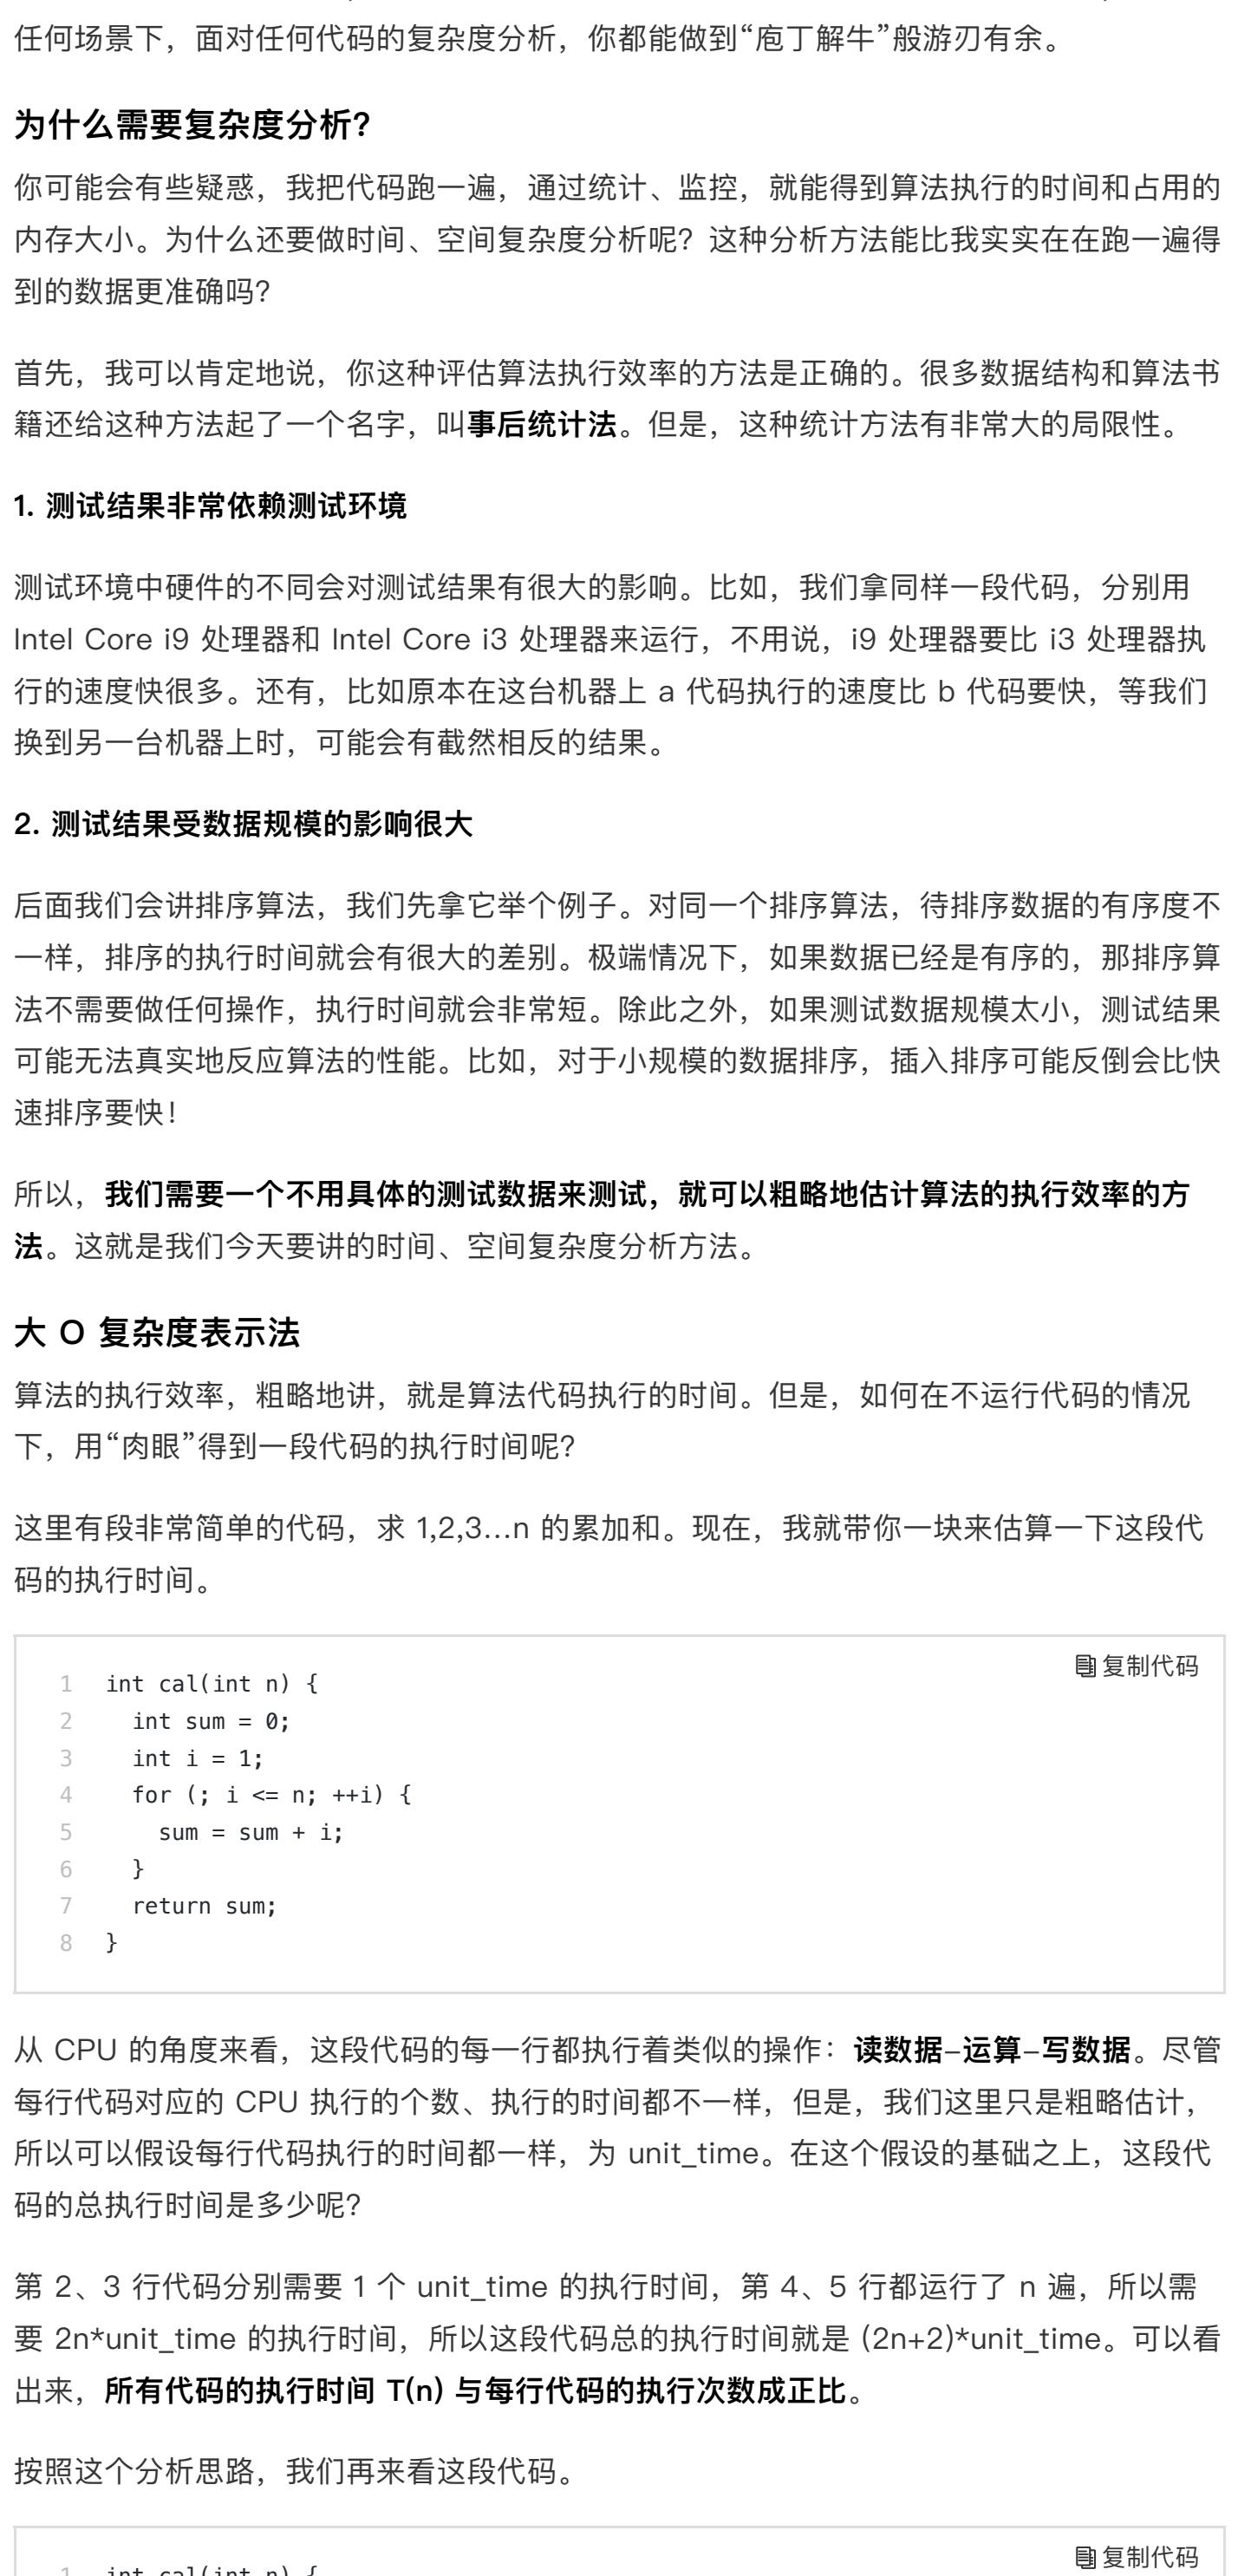


03 | 复杂度分析（上）：如何分析、统计算法的执行效率和资源消耗？

2018-09-26 王争



03 | 复杂度分析（上）：如何分析、统计算法的执行效率和资源消耗？

朗读人：修阳 19'42" | 9.04M

我们都知道，数据结构和算法本身解决的是“快”和“省”的问题，即如何让代码运行得更快，如何让代码更省存储空间。所以，执行效率是算法一个非常重要的考量指标。那如何来衡量你编写的算法代码的执行效率呢？这里就要用到我们今天要讲的内容：时间、空间复杂度分析。

其实，只要讲到数据结构与算法，就一定离不开时间、空间复杂度分析。而且，我个人认为，**复杂度分析是整个算法学习的精髓，只要掌握了它，数据结构和算法的内容基本上就掌握了一半**。

复杂度分析实在太重要了，因此我准备用两节内容来讲。希望你学完这个内容之后，无论在任何场景下，面对任何代码的复杂度分析，你都能做到“庖丁解牛”般游刃有余。

为什么需要复杂度分析？

你可能会有些疑惑，我把代码跑一遍，通过统计、监控，就能得到算法执行的时间和占用的内存大小。为什么还要做时间、空间复杂度分析呢？这种分析方法能比我实实在在跑一遍得到的数据更准确吗？

首先，我可以肯定地说，你这种评估算法执行效率的方法是正确的。很多数据结构和算法书籍还给这种方法起了一个名字，叫**事后统计法**。但是，这种统计方法有非常大的局限性。

1. 测试结果非常依赖测试环境

测试环境中硬件的不同会对测试结果有很大的影响。比如，我们拿同样一段代码，分别用 Intel Core i9 处理器和 Intel Core i3 处理器来运行。不用说，i9 处理器要比 i3 处理器执行的速度快很多。还有，比如原本在这台机器上 a 代码执行的速度比 b 代码要快，等我们换到另一台机器上时，可能会有截然相反的结果。

2. 测试结果受数据规模的影响很大

后面我们会讲排序算法，我们先拿它举个例子。对同一个排序算法，待排序数据的有序度不一样，排序的执行时间就会有很大的差别。极端情况下，如果数据已经是有序的，那排序算法不需要做任何操作，执行时间就会非常短。除此之外，如果测试数据规模太小，测试结果可能无法真实地反应算法的性能。比如，对于小规模的数据排序，插入排序可能反倒会比快速排序要快！

所以，**我们需要一个不用具体的测试数据来测试，就可以粗略地估计算法的执行效率的方法**。这就是我们今天要讲的时间、空间复杂度分析方法。

大 O 复杂度表示法

算法的执行效率，粗略地讲，就是算法代码执行的时间。但是，如何在不运行代码的情况下，用“肉眼”得到一段代码的执行时间呢？

这里有段非常简单的代码，求 1,2,3...n 的累加和。现在，我就带你一块来估算一下这段代码的执行时间。

```
1 int cal(int n) {
2     int sum = 0;
3     int i = 1;
4     for (; i <= n; ++i) {
5         sum = sum + i;
6     }
7     return sum;
8 }
```

从 CPU 的角度来看，这段代码的每一行都执行着类似的操作：**读数据-运算-写数据**。尽管每行代码对应的 CPU 执行的个数、执行的时间都不一样，但是，我们这里只是粗略估计，所以可以假设每行代码执行的时间都一样，为 unit_time。在这个假设的基础之上，这段代码的总执行时间是多少呢？

第 2、3 行代码分别需要 1 个 unit_time 的执行时间，第 4、5 行都运行了 n 遍，所以需要 $2n * \text{unit_time}$ 的执行时间，所以这段代码总的执行时间就是 $(2n+2) * \text{unit_time}$ 。可以看出来，**所有代码的执行时间 T(n) 与每行代码的执行次数成正比**。

按照这个分析思路，我们再来看这段代码。

```
1 int cal(int n) {
2     int sum = 0;
3     int i = 1;
4     int j = 1;
5     for (; i <= n; ++i) {
6         j = 1;
7         for (; j <= n; ++j) {
8             sum = sum + i * j;
9         }
10    }
11 }
```

我们依旧假设每个语句的执行时间是 unit_time。那这段代码的总执行时间 $T(n)$ 是多少呢？

第 2、3、4 行代码，每行都需要 1 个 unit_time 的执行时间，第 5、6 行代码循环执行了 n 遍，需要 $n * \text{unit_time}$ 的执行时间，第 7、8 行代码循环执行了 n^2 遍，所以需要 $2n^2 * \text{unit_time}$ 的执行时间。所以，整段代码总的执行时间 $T(n) = (2n^2+2n+3) * \text{unit_time}$ 。

尽管我们不知道 unit_time 的具体值，但是通过这两段代码执行时间的推导过程，我们可以得到一个非常重要的规律，那就是，**所有代码的执行时间 T(n) 与每行代码的执行次数 n 成正比**。

我们可以把这个规律总结成一个公式。注意，**大 O 就要登场了！**

$$T(n) = O(f(n))$$

我来具体解释一下这个公式。其中， $T(n)$ 我们已经讲过了，它表示代码执行的时间； n 表示数据规模的大小； $f(n)$ 表示每行代码执行的次数总和。因为这是一个公式，所以用 $f(n)$ 来表示。公式中的 O ，表示代码的执行时间 $T(n)$ 与 $f(n)$ 表达式成正比。

所以，第一个例子中的 $T(n) = O(2n+2)$ ，第二个例子中的 $T(n) = O(2n^2+2n+3)$ 。这就是**大 O 时间复杂度表示法**。大 O 时间复杂度实际上并不具体表示代码真正的执行时间，而是表示代码执行时间随数据规模增长的变化趋势，所以，也叫作**渐进时间复杂度** (asymptotic time complexity)，简称**时间复杂度**。

当 n 很大时，你可以把它想象成 10000、100000。而公式中的低阶、常量、系数三部分并不左右增长趋势，所以都可以忽略。我们只需要记录一个最大量级就可以了，如果用大 O 表示法表示刚讲的那两段代码的时间复杂度，就可以记为： $T(n) = O(n)$ ； $T(n) = O(n^2)$ 。

时间复杂度分析

前面介绍了大 O 时间复杂度的由来和表示方法。现在我们来看下，如何分析一段代码的时间复杂度？我这儿有三个比较实用的方法可以分享给你。

1. 只关注循环执行次数最多的一段代码

我刚才说了，大 O 这种复杂度表示方法只是表示一种变化趋势。我们通常会忽略掉公式中的常量、低阶、系数，只需要记录一个最大阶的量级就可以了。所以，我们在分析一个算法、一段代码的时间复杂度的时候，也只关注循环执行次数最多的那一段代码就可以了。这段核心代码执行次数的 n 的量级，就是整段要分析代码的时间复杂度。

为了便于你理解，我还拿前面的例子来说明。

```
1 int cal(int n) {
2     int sum = 0;
3     int i = 1;
4     for (; i <= n; ++i) {
5         sum = sum + i;
6     }
7     return sum;
8 }
```

其中第 2、3 行代码都是常量级的执行时间，与 n 的大小无关，所以对于复杂度并没有影响。循环执行次数最多的是第 4、5 行代码，所以这块代码要重点分析。前面我们也讲过，这两行代码被执行了 n 次，所以总的时间复杂度就是 $O(n)$ 。

2. 加法法则：总复杂度等于量级最大的那段代码的复杂度

我这里还有一段代码。你可以先试着分析一下，然后再往下看跟我的分析思路是否一样。

```
1 int cal(int n) {
2     int sum_1 = 0;
3     int p = 1;
4     for (; p < 100; ++p) {
5         sum_1 = sum_1 + p;
6     }
7
8     int sum_2 = 0;
9     int q = 1;
10    for (; q < n; ++q) {
11        sum_2 = sum_2 + q;
12    }
13
14    int sum_3 = 0;
15    int i = 1;
16    int j = 1;
17    for (; i <= n; ++i) {
18        j = 1;
19        for (; j <= n; ++j) {
20            sum_3 = sum_3 + i * j;
21        }
22    }
23
24    return sum_1 + sum_2 + sum_3;
25 }
```

根据我们前面讲的复杂度分析方法，第三行代码是循环执行次数最多的，所以只要能计算出这行代码被执行了多少次，就能知道整段代码的时间复杂度。

从代码中可以看出，变量 i 的值从 1 开始取，每循环一次就乘以 2。当大于 n 时，循环结束。还记得我们高中学过的等比数列吗？实际上，变量 i 的取值就是一个等比数列。如果把它一个一个列出来，就应该是这个样子的：

$$2^0, 2^1, 2^2, \dots, 2^k, \dots, 2^n = n$$

所以，我们只要知道 x 值是多少，就知道这行代码执行的次数了。通过 $2^x=n$ 求解 x 这个问题我们想高中应该就学过了，我就不多说了。 $x=\log_2 n$ ，所以，这段代码的时间复杂度就是 $O(\log_2 n)$ 。

也就是说，假设 $T_1(n) = O(n)$ ， $T_2(n) = O(n^2)$ ，则 $T_1(n) * T_2(n) = O(n^3)$ 。落实到具体的代码上，我们可以把乘法法则看成是**嵌套循环**，我举个例子给你解释一下。

```
1 int cal(int n) {
2     int ret = 0;
3     int i = 1;
4     for (; i < n; ++i) {
5         ret = ret + f(i);
6     }
7
8     int sum = 0;
9     int j = 1;
10    for (; j < n; ++j) {
11        sum = sum + j;
12    }
13
14    return sum;
15 }
```

我们单独看 $cal()$ 函数。假设 $f()$ 只是一个普通的操作，那第 4~6 行的时间复杂度就是 $T_1(n) = O(n)$ 。但 $f()$ 函数本身不是一个简单的操作，它的执行时间复杂度是 $T_2(n) = O(n)$ ，所以，整个 $cal()$ 函数的时间复杂度就是 $T(n) = O(n) * O(n) = O(n^2)$ 。

3. 乘法法则：嵌套代码的复杂度等于嵌套内外代码复杂度的乘积

我们再来讲一种跟前面都不一样的时间复杂度分析方法。类比一下，你应该能“猜到”公式是什么样子的吧？

```
1 void print(int n) {
2     int i = 1;
3     while (i <= n) {
4         i = i * 3;
5     }
6
7     int a[10];
8     for (int j = 0; j < 10; j++) {
9         a[j] = j;
10    }
11 }
```

根据我们前面讲的复杂度分析方法，第三行代码是循环执行次数最多的，所以只要能计算出这行代码被执行了多少次，就能知道整段代码的时间复杂度。

从代码中可以看出，变量 i 的值从 1 开始取，每循环一次就乘以 3。当大于 n 时，循环结束。还记得我们高中学过的等比数列吗？实际上，变量 i 的取值就是一个等比数列。如果把它一个一个列出来，就应该是这个样子的：

$$3^0, 3^1, 3^2, \dots, 3^k, \dots, 3^n = n$$

所以，我们只要知道 x 值是多少，就知道这行代码执行的次数了。通过 $3^x=n$ 求解 x 这个问题我们想高中应该就学过了，我就不多说了。 $x=\log_3 n$ ，所以，这段代码的时间复杂度就是 $O(\log_3 n)$ 。

实际上，不管是以 2 为底，还是以 10 为底，我们都可以把所有对数阶的时间复杂度都记为 $O(\log n)$ 。为什么呢？

```
1 int cal(int m, int n) {
2     int sum_1 = 0;
3     int sum_2 = 0;
4     int sum_3 = 0;
5     for (int i = 1; i <= m; i++) {
6         sum_1 = sum_1 + i;
7     }
8
9     for (int j = 1; j <= n; j++) {
10        sum_2 = sum_2 + j;
11    }
12
13    for (int k = 1; k <= m * n; k++) {
14        sum_3 = sum_3 + k;
15    }
16
17    return sum_1 + sum_2 + sum_3;
18 }
```

从代码中可以看出， m 和 n 是表示两个数据规模。我们无法事先评估 m 和 n 的量级，所以对于复杂度并没有影响。循环执行次数最多的是第 5、6 行代码，所以这块代码要重点分析。前面我们也讲过，这两行代码被执行了 m 次，所以总的时间复杂度就是 $O(m)$ 。

针对这种情况，原来的加法法则就不正确了，我们需要将加法规则改为： $T_1(m) + T_2(n) = \max(O(f(m)), O(g(n)))$ 。但是乘法法则继续有效： $T_1(m) * T_2(n) = O(f(m) * g(n))$ 。

```
1 int cal(int m, int n) {
2     int sum_1 = 0;
3     int sum_2 = 0;
4     int sum_3 = 0;
5     for (int i = 1; i <= m; i++) {
6         sum_1 = sum_1 + i;
7     }
8
9     for (int j = 1; j <= n; j++) {
10        sum_2 = sum_2 + j;
11    }
12
13    for (int k = 1; k <= m * n; k++) {
14        sum_3 = sum_3 + k;
15    }
16
17    return sum_1 + sum_2 + sum_3;
18 }
```

从代码中可以看出， m 和 n 是表示两个数据规模。我们无法事先评估 m 和 n 的量级，所以对于复杂度并没有影响。循环执行次数最多的是第 5、6 行代码，所以这块代码要重点分析。前面我们也讲过，这两行代码被执行了 m 次，所以总的时间复杂度就是 $O(m)$ 。

针对这种情况，原来的加法法则就不正确了，我们需要将加法规则改为： $T_1(m) + T_2(n) = \max(O(f(m)), O(g(n)))$ 。但是乘法法则继续有效： $T_1(m) * T_2(n) = O(f(m) * g(n))$ 。

```
1 void print(int n) {
2     int i = 1;
3     while (i <= n) {
4         i = i * 3;
5     }
6
7     int a[10];
8     for (int j = 0; j < 10; j++) {
9         a[j] = j;
10    }
11 }
```

从代码中可以看出，变量 i 的值从 1 开始取，每循环一次就乘以 3。当大于 n 时，循环结束。还记得我们高中学过的等比数列吗？实际上，变量 i 的取值就是一个等比数列。如果把它一个一个列出来，就应该是这个样子的：

$$3^0, 3^1, 3^2, \dots, 3^k, \dots, 3^n = n$$

所以，我们只要知道 x 值是多少，就知道这行代码执行的次数了。通过 $3^x=n$ 求解 x 这个问题我们想高中应该就学过了，我就不多说了。 $x=\log_3 n$ ，所以，这段代码的时间复杂度就是 $O(\log_3 n)$ 。

实际上，不管是以 2 为底，还是以 10 为底，我们都可以把所有对数阶的时间复杂度都记为 $O(\log n)$ 。为什么呢？

```
1 int cal(int m, int n) {
2     int sum_1 = 0;
3     int sum_2 = 0;
4     int sum_3 = 0;
5     for (int i = 1; i <= m; i++) {
6         sum_1 = sum_1 + i;
7     }
8
9     for (int j = 1; j <= n; j++) {
10        sum_2 = sum_2 + j;
11    }
12
13    for (int k = 1; k <= m * n; k++) {
14        sum_3 = sum_3 + k;
15    }
16
17    return sum_1 + sum_2 + sum_3;
18 }
```

从代码中可以看出， m 和 n 是表示两个数据规模。我们无法事先评估 m 和 n 的量级，所以对于复杂度并没有影响。循环执行次数最多的是第 5、6 行代码，所以这块代码要重点分析。前面我们也讲过，这两行代码被执行了 m 次，所以总的时间复杂度就是 $O(m)$ 。

针对这种情况，原来的加法法则就不正确了，我们需要将加法规则改为： $T_1(m) + T_2(n) = \max(O(f(m)), O(g(n)))$ 。但是乘法法则继续有效： $T_1(m) * T_2(n) = O(f(m) * g(n))$ 。

```
1 void print(int n) {
2     int i = 1;
3     while (i <= n) {
4         i = i * 3;
5     }
6
7     int a[10];
8     for (int j = 0; j < 10; j++) {
9         a[j] = j;
10    }
11 }
```

从代码中可以看出，变量 i 的值从 1 开始取，每循环一次就乘以 3。当大于 n 时，循环结束。还记得我们高中学过的等比数列吗？实际上，变量 i 的取值就是一个等比数列。如果把它一个一个列出来，就应该是这个样子的：

$$3^0, 3^1, 3^2, \dots, 3^k, \dots, 3^n = n$$

所以，我们只要知道 x 值是多少，就知道这行代码执行的次数了。通过 $3^x=n$ 求解 x 这个问题我们想高中应该就学过了，我就不多说了。 $x=\log_3 n$ ，所以，这段代码的时间复杂度就是 $O(\log_3 n)$ 。

实际上，不管是以 2 为底，还是以 10 为底，我们都可以把所有对数阶的时间复杂度都记为 $O(\log n)$ 。为什么呢？

```
1 int cal(int m, int n) {
2     int sum_1 = 0;
3     int sum_2 = 0;
4     int sum_3 = 0;
5     for (int i = 1; i <= m; i++) {
6         sum_1 = sum_1 + i;
7     }
8
9     for (int j = 1; j <= n; j++) {
10        sum_2 = sum_2 + j;
11    }
12
13    for (int k = 1; k <= m * n; k++) {
14        sum_3 = sum_3 + k;
15    }
16
17    return sum_1 + sum_2 + sum_3;
18 }
```

从代码中可以看出， m 和 n 是表示两个数据规模。我们无法事先评估 m